LEZIONE 1 DI 3 · SCUOLA SUPERIORE

Come «ragiona» un’intelligenza artificiale?

Museo CTRL+Alt, Pavia · Università di Pavia

Come fa ChatGPT a rispondere?

Tre risposte che si sentono spesso. Nessuna delle tre è giusta.

SBAGLIATO 01

«Cerca su internet»

Mentre scrive la risposta non è collegato a niente.

SBAGLIATO 02

«Ha un archivio di risposte»

Dentro non c’è nemmeno una frase salvata.

SBAGLIATO 03

«Ragiona come noi»

Fra venti minuti saprete esattamente perché no.

Partiamo da un’immagine: lo studente



Ha letto tutto. Ma quando non sa, risponde lo stesso.

Immagine ripresa da Sara Zan, «Explain me LLMs like I’m five» (2024)

PERÒ

Uno studente *capisce* quello che legge.
Questo no.

Non sa cosa sia il mare, né un gatto, né la tristezza.
Allora cosa fa, esattamente?

L’IDEA DI TUTTA LA LEZIONE

Un LLM fa una cosa sola: prevede la parola successiva.

Le poesie, i temi, il codice, le traduzioni, i riassunti.
Tutto nasce da qui. Non c’è nient’altro.

ATTIVITÀ · 3 MINUTI

Proviamo noi. Completate ad alta voce.

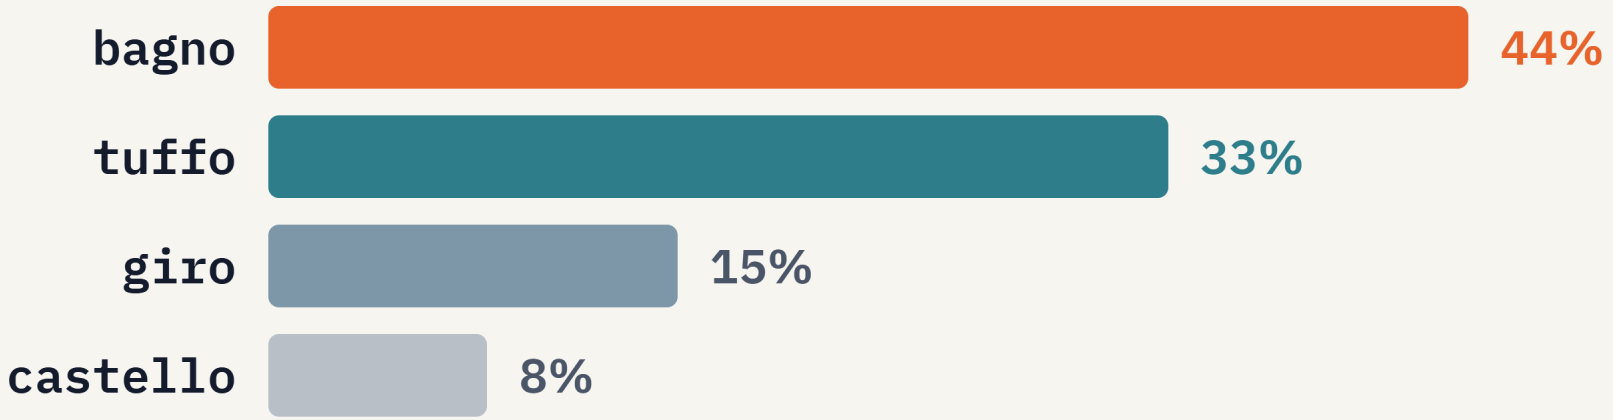
Chi dorme non piglia _____

Ieri sono andato al mare e ho fatto un _____

Avete appena fatto esattamente quello che fa il modello.

Non esiste *una* risposta giusta

`Ieri sono andato al mare e ho fatto un ________`



Il modello **non sceglie** una parola: calcola **quanto è probabile ognuna**. Poi sceglie. Sono due passaggi diversi, e fra poco vediamo il secondo.

Da dove vengono quelle probabilità?

Ha letto

Miliardi di pagine: libri, siti, articoli, codice, conversazioni.

Ma non ricorda

Non ha salvato quelle pagine. Ha imparato gli **schemi**: quali parole stanno vicine a quali altre.

Una volta sola

Finito l'addestramento, si ferma lì. Non impara dalle vostre chat.

TORNIAMO ALLE TRE RISPOSTE SBAGLIATE

Niente ricerca su internet. Nessun archivio di frasi. Solo schemi, imparati una volta e poi congelati.

Dentro la scatola: tre mestieri

Per arrivare a quella lista di probabilità il modello fa tre lavori, uno dopo l'altro.

01

Le parole diventano numeri

Il computer non sa leggere. Sa solo contare.

02

L'attenzione pesa le parole

Quali parole della frase contano davvero?

03

Esce la lista delle probabilità

Un punteggio per ogni parola del vocabolario.

L'**attenzione** è il cuore del **Transformer**: l'architettura di tutte queste IA.

La catena di montaggio

Gli stessi tre mestieri, ma visti dentro la macchina. Questa macchina si chiama **Transformer**.



E poi **ricomincia da capo**: la parola appena scelta torna all'inizio e la macchina rifà tutto il giro per la parola dopo.

MESTIERE 01

Le parole diventano numeri

La frase viene spezzata in pezzetti chiamati **token**. Ogni token ha un numero. Leggiamo anche noi così: a blocchi, non lettera per lettera.

Ieri	sono	andato	al	mare
8421	319	5107	64	2290

Un token non è sempre una parola intera: «straordinariamente» diventa **stra · ordinaria · mente**.

La mappa dei significati

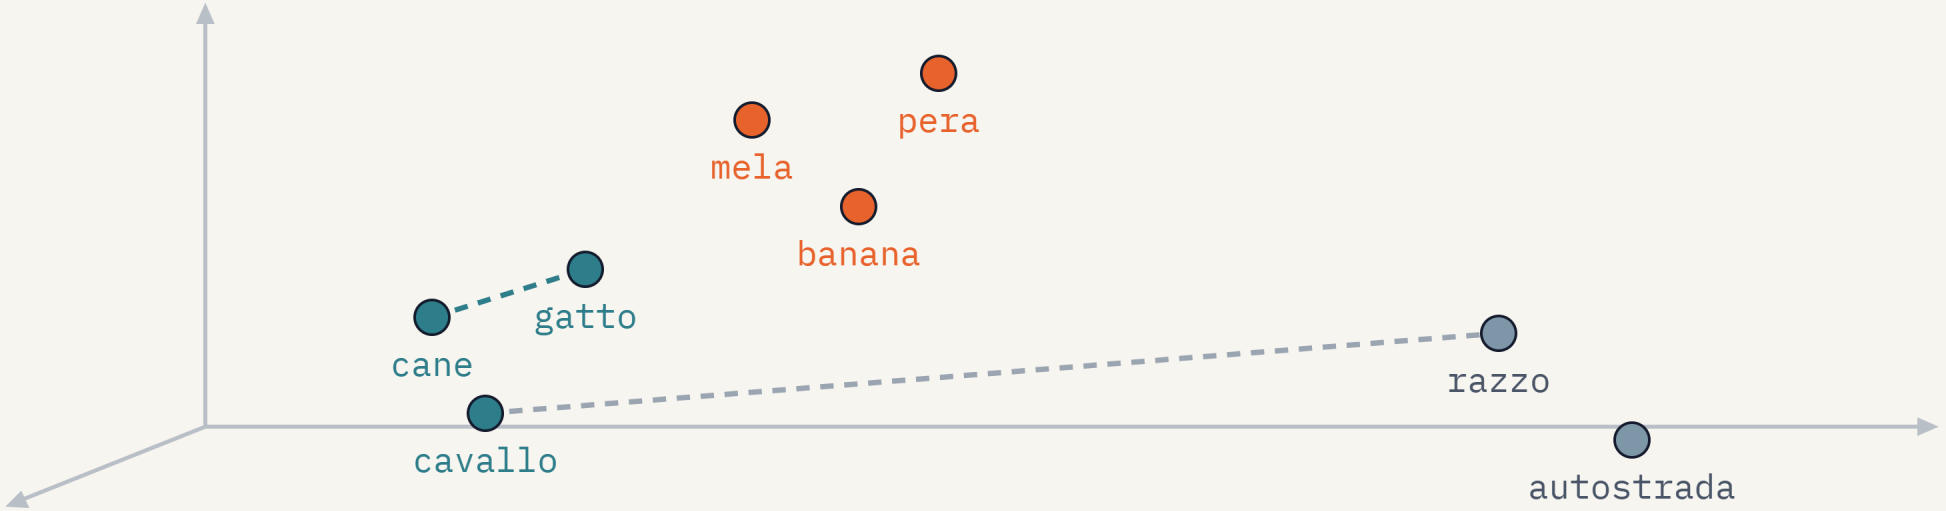
I numeri non sono messi a caso. Ogni parola riceve un posto su una mappa: le parole che si usano in modo simile finiscono **vicine**.



«computer» è lì in mezzo per colpa di una certa azienda. Il modello l'ha imparato leggendo, non ragionando.

Vicine o lontane: lo spazio degli embedding

Ogni parola è un punto in questo spazio. **La distanza fra due punti misura quanto le due parole si somigliano.**



Vicine: significato simile

Lontane: significati diversi

Una mappa vera, con migliaia di parole e decine di dimensioni: **projector.tensorflow.org**

MESTIERE 02

L’attenzione: quali parole contano

La stessa parola può voler dire cose diverse. A decidere sono le parole intorno.

Marco ha **mangiato** una **pesca** **matura**.

→ il frutto. Lo decidono «mangiato» e «matura».

Marco è **andato** a **pesca** sul **lago**.

→ l’attività. Lo decidono «andato» e «lago».

Come quando prendete appunti: non scrivete tutto, pesate quello che conta.

APPROFONDIMENTO

Come assegna i pesi: Q, K, V

Q

Query

«Che cosa sto cercando?»

La domanda che ogni parola fa alle altre.

K

Key

«Che cosa posso offrire?»

L’etichetta con cui ogni parola si presenta.

V

Value

«Ecco il mio contenuto.»

L’informazione che passa, pesata dal punteggio.

E SI FA IN PIÙ MODI INSIEME: MULTI-HEAD ATTENTION

Come guardare un quadro da più angoli contemporaneamente: una «testa» segue la grammatica, un’altra il significato, un’altra ancora chi-fa-cosa.

APPROFONDIMENTO

Il Transformer

L’architettura che sta sotto a tutti questi modelli. Nasce nel **2017**, in un articolo di Google con un titolo che è già un riassunto: *«Attention Is All You Need»*.

Legge tutta la frase insieme

I modelli precedenti leggevano una parola alla volta, in fila, e verso la fine di un testo lungo si erano già dimenticati l’inizio.

Fa i conti in parallelo

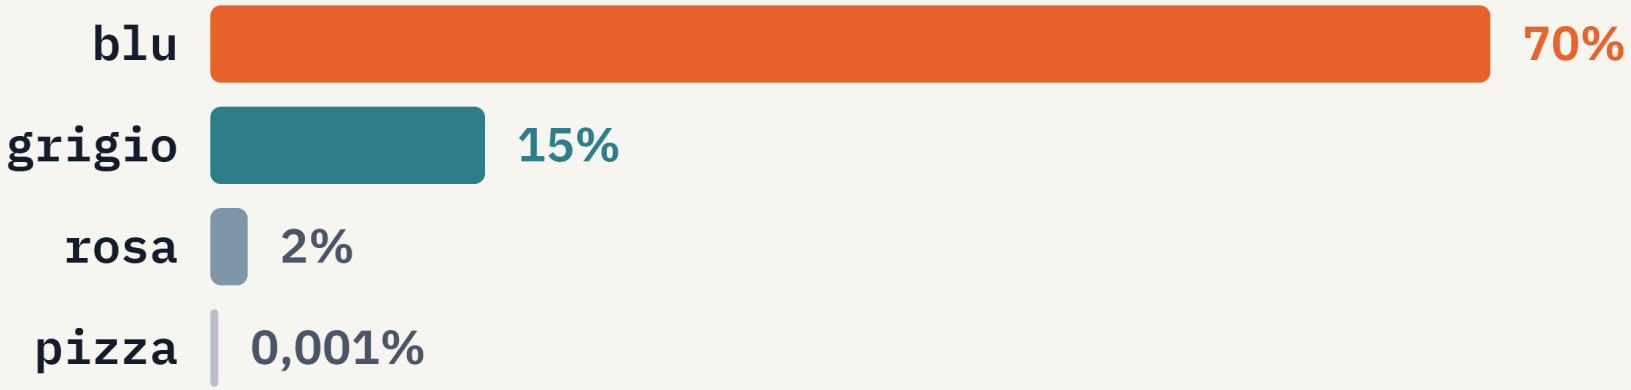
Migliaia di calcoli nello stesso istante, invece che in coda. È questo che ha reso possibile addestrare modelli così grandi.

La T di **GPT** e di **BERT** sta per Transformer.

MESTIERE 03

Esce la lista delle probabilità

Di che colore è il cielo?



«pizza» non vale zero. Vale pochissimo. Tenete a mente questa differenza.

APPROFONDIMENTO

Da punteggi a probabilità: la softmax

La rete non produce direttamente delle percentuali: produce **punteggi grezzi**, chiamati **logits**. Possono essere grandi, piccoli, anche negativi. La softmax li trasforma in probabilità che sommano a 1.

LOGITS (u)	
bagno	1.2
tuffo	0.9
giro	0.1
castello	−0.5

softmax



PROBABILITÀ (y)	
bagno	0.44
tuffo	0.33
giro	0.15
castello	0.08

$$\frac{\exp(\text{punteggio})}{\text{somma degli exp di tutte le parole}}$$

In forma compatta: **y = softmax(u)** · le quattro probabilità sommano a 1.00

La catena di montaggio

Adesso che li avete aperti tutti e tre, guardate di nuovo la macchina intera.



E poi **ricomincia da capo**: la parola appena scelta torna all'inizio e la macchina rifà tutto il giro per la parola dopo.

Scelta 1: prendi sempre la più probabile

Si chiama **decodifica greedy**, cioè «avida». A ogni passo prende il massimo e non si volta indietro.

bagno	**0.44**
tuffo	0.33
giro	0.15
castello	0.08

IN NOTAZIONE

```
w = argmax P(w | testo precedente)
```

«Fra tutte le parole del vocabolario, dammi quella con la probabilità più alta.»

Sceglie il meglio *adesso*, senza sapere se fra cinque parole se ne pentirà.

Sembra la scelta ovvia. La prossima slide spiega perché quasi nessuno la usa.

Però quasi nessuno la usa

Sempre uguale

Stessa domanda, stessa identica risposta. Ogni volta, per sempre. È **deterministica**.

Banale

Prendere sempre la parola più prevedibile produce, per definizione, il testo più prevedibile possibile.

Ripetitiva

Spesso si incastra in giri a vuoto e ripete la stessa frase all’infinito.

LA DOMANDA CHE VI SARETE FATTI

«Perché se rifaccio la stessa domanda mi risponde in modo diverso?»

Ecco perché: non prende la più probabile. Fa qualcos’altro.

Scelta 2: il campionamento

Invece di prendere sempre la prima, **tira a sorte**, ma con un dado truccato: ogni parola esce con la sua probabilità.

Come una roulette

«bagno» occupa il 44% della ruota, «tuffo» il 33%, «castello» solo l’8%.

Lanci la pallina. Di solito esce bagno. A volte esce castello. Quasi mai esce pizza, ma **può succedere**.

IL CICLO, IN PSEUDOCODICE

```
i = 1
estrai w(1) secondo le sue probabilità
finché w(i) non è FINE:
    i = i + 1
    estrai w(i) dato tutto
    quello che c’è prima
```

LA MANOPOLA: TEMPERATURA

Bassa → la ruota si sbilancia sulle parole sicure, il testo diventa piatto. Alta → tutte le parole si avvicinano, il testo diventa creativo e poi delirante.

Questa è la risposta tecnica alla domanda di prima. Ogni risposta è un lancio di dadi.

E poi ricomincia da capo

Il modello non scrive la risposta tutta insieme. Scrive **una parola**, se la rimette davanti, e rifà tutto il giro.

```
Cosa mangiano i gatti?
I _ _ _ _ _
I gatti _ _ _ _
I gatti mangiano _ _ _
I gatti mangiano pesce _ _
I gatti mangiano pesce e crocchette.
```

Ogni riga è **un giro completo** dei tre mestieri. Per una risposta di 200 parole, 200 giri.

Ecco perché la risposta **appare a pezzetti** sullo schermo: la state guardando mentre viene costruita.

Nome tecnico: generazione **autoregressiva**, cioè «si nutre di quello che ha appena scritto».

Quindi *non capisce*. E si vede.

Non sa cosa sia un gatto. Sa quali parole stanno vicino a «gatto». Da questo discendono tre cose molto concrete.

Allucinazioni

Inventa fatti, libri, leggi, articoli, scritti benissimo e completamente falsi.

Per lui ogni domanda è un'interrogazione: conviene inventare qualcosa piuttosto che ammettere di non sapere.

Pregiudizi

Ha imparato dai testi scritti da noi. Se in quei testi c'erano pregiudizi, li ha imparati anche quelli.

Non è cattivo: sta ripetendo uno schema che ha visto molte volte.

Non sa che giorno è

La sua lettura si è fermata a una certa data. Dopo, il buio.

A meno che non gli diate voi i documenti: è il «compito a libro aperto».

Da portare a casa

01 Un LLM **prevede la parola successiva**. Tutto il resto nasce da qui.

02 Le parole diventano **numeri su una mappa**, dove le parole simili stanno vicine.

03 L'**attenzione** decide quali parole della frase contano di più.

04 Non esce una parola, esce una **lista di probabilità**. Poi si tira a sorte.

05 Scrive **una parola alla volta**, e non sa come finirà la frase.

Non c'è un cervellino dentro la scatola.

C'è una macchina che indovina la parola successiva, e lo fa molto bene.

LEZIONE 2

Se segue il testo che legge... cosa succede se qualcuno ci **nasconde dentro delle istruzioni**?